

COMPONENTE CURRICULAR:	PROJETO APLICADO III
NOME COMPLETO DO ALUNO:	CRISTINA ALMEIDA DA SILVA – RA 10424207 BRENDA LOUIZE DE O. SOUSA CABRAL – RA 10424949 ÉLIDA ROSA DE PAIVA SOUZA – RA 10424468 ISABEL CABRAL VIEIRA DE SOUSA – RA 1042479

TÍTULO: SISTEMA DE RECOMENDAÇÃO DE LIVROS

1. INTRODUÇÃO	3
1.1. CONTEXTO DO TRABALHO	4
1.2. MOTIVAÇÃO	4
1.3. JUSTIFICATIVA	5
1.4. OBJETIVO GERAL E OBJETIVOS ESPECÍFICOS DA PESQUISA	6
2. REFERENCIAL TEÓRICO.....	7
3. METODOLOGIA	9
4. RESULTADOS	11
4.1. RESULTADOS PRELIMINARES	11
4.2. AJUSTES E MELHORIAS DO PIPELINE	12
4.3. REAVALIAÇÃO DO DESEMPENHO DO MODELO	13
REFERÊNCIAS	15

1. INTRODUÇÃO

Na sociedade contemporânea, marcada pela abundância de informações digitais, identificar conteúdos relevantes tornou-se um desafio recorrente para usuários de diferentes perfis. Em ambientes digitais como plataformas de leitura, livrarias online e bibliotecas virtuais, a vasta quantidade de títulos disponíveis frequentemente resulta em sobrecarga informacional, dificultando a descoberta de obras alinhadas aos interesses individuais dos leitores (Ricci, Rokach & Shapira, 2022). Essa realidade despertou o interesse por soluções que possam tornar essa experiência mais eficiente, personalizada e intuitiva. Nesse contexto, surgiu a motivação para investigar como sistemas de recomendação podem contribuir para otimizar a descoberta de livros em ambientes digitais.

A escolha do tema foi impulsionada pela observação de que, apesar do avanço das tecnologias de informação, muitos leitores ainda enfrentam dificuldades para encontrar obras alinhadas aos seus gostos e necessidades. Plataformas de leitura e livrarias digitais oferecem milhares de títulos, mas nem sempre proporcionam sugestões realmente personalizadas. Esse cenário evidenciou a existência de um problema: **como recomendar livros relevantes a usuários com pouca ou nenhuma interação prévia, promovendo uma experiência de leitura mais rica, personalizada e inclusiva?**

A hipótese central do projeto é que a aplicação de técnicas de aprendizado de máquina, especialmente a filtragem colaborativa (como o SVD), podem gerar boas recomendações mesmo em bases de dados esparsas, mitigando problemas como início frio e baixa diversidade (Koren, Bell, Volinsky, 2009).

Para isso, será utilizada a base de dados pública Book-Crossing Dataset, que contém informações sobre livros, usuários e avaliações. A expectativa é que, ao estruturar um pipeline eficiente de pré-processamento, modelagem e avaliação, seja possível construir um protótipo funcional de recomendação de livros que possa ser aplicado em plataformas digitais de leitura.

Além do valor técnico e acadêmico, o projeto também possui uma dimensão social, ao propor soluções que incentivam o hábito da leitura, democratizam o acesso ao conhecimento e promovem práticas educacionais mais eficientes e sustentáveis — alinhadas aos Objetivos de Desenvolvimento Sustentável (ODS), como Educação de Qualidade (ODS 4), Inovação e Infraestrutura (ODS 9) e Redução das Desigualdades (ODS 10).

Assim, este projeto busca aplicar conhecimentos adquiridos ao longo da graduação em Ciência de Dados para propor uma solução tecnológica com impacto prático, tanto no setor editorial quanto na promoção da inclusão digital e educacional.

1.1. CONTEXTO DO TRABALHO

Com o crescimento exponencial das informações disponíveis na internet, identificar conteúdos relevantes de maneira eficiente tornou-se um desafio significativo para os usuários. Nesse cenário, os sistemas de recomendação surgem como ferramentas essenciais para personalizar a experiência do usuário, auxiliando na descoberta de livros compatíveis com os interesses individuais. Esses sistemas são amplamente utilizados em plataformas de streaming, e-commerce, redes sociais, bibliotecas digitais e ambientes educacionais, impactando diretamente a experiência de leitura com base em dados de comportamento e preferências anteriores (Resnick; Varian, 1997).

Para o desenvolvimento deste projeto, foi selecionada a base de dados Book-Crossing Dataset, disponibilizada na plataforma Kaggle. Essa base, originalmente coletada por Cai-Nicolas Ziegler em 2004, contém três arquivos principais: dados dos livros, dados dos usuários e dados de avaliação de livros. Essa base oferece um histórico valioso para a construção de um modelo de recomendação, embora apresente limitações, como esparsidade dos dados e inconsistências em registros de idade dos usuários.

1.2. MOTIVAÇÃO

A intensa demanda por soluções personalizadas, sobretudo em um ambiente saturado de informações como a internet, tem impulsionado o desenvolvimento de sistemas de recomendação mais eficazes. Segundo Resnick & Varian (1997), os sistemas de recomendação desempenham um papel crucial ao ajudar os usuários a filtrar a vasta quantidade de opções disponíveis, promovendo uma experiência mais direcionada e personalizada. Neste contexto, o uso de técnicas de aprendizado de máquina, que lidam com grandes volumes de dados e buscam melhorar a precisão das recomendações, torna-se essencial. Aggarwal (2016) destaca que algoritmos de aprendizado de máquina podem não apenas melhorar a relevância das sugestões, mas também lidar com a dinâmica e a complexidade dos dados comportamentais dos usuários.

A escolha de trabalhar com a recomendação de livros está alinhada à necessidade de aprimorar a experiência do usuário, oferecendo sugestões personalizadas e ajustadas aos seus gostos e comportamentos de leitura. Como afirmam Ricci, Rokach & Shapira

(2015), a personalização é fundamental para melhorar a satisfação do usuário, tornando a interação com plataformas de conteúdo mais relevante e engajante, além de permitir a aplicação prática de técnicas de aprendizado de máquina, habilidade essencial para cientistas de dados.

1.3. JUSTIFICATIVA

A escolha de um sistema de recomendação de livros é justificada pela sua relevância crescente no mercado editorial digital, que tem visto uma transição de vendas físicas para plataformas digitais. De acordo com Jannach et al. (2010), a personalização em sistemas de recomendação tem se mostrado uma ferramenta poderosa para melhorar a experiência do usuário em plataformas digitais, oferecendo não apenas maior satisfação, mas também fidelização do público. Com uma quantidade crescente de títulos e resenhas disponíveis online, o problema de ajudar os leitores a selecionar livros relevantes se torna cada vez mais urgente, como apontado por Basilico & Ricci (2004), que discutem a importância de personalizar as recomendações para garantir que o usuário encontre facilmente o conteúdo que mais lhe interessa.

Além disso, a aplicação de técnicas como a filtragem colaborativa permite criar modelos mais eficientes, mesmo em bases com interações limitadas tornando esse processo mais eficiente, como também garantindo uma experiência mais fluida e satisfatória para o usuário, como argumenta Schafer et al. (2007), a aplicação de modelos avançados de recomendação, pode oferecer resultados mais precisos e adaptativos, proporcionando uma experiência personalizada e ajustada às preferências do usuário.

A justificativa também se apoia no impacto direto que um sistema de recomendação de livros pode ter em plataformas de leitura, livrarias online e bibliotecas digitais. Ricci et al. (2015) afirmam que os sistemas de recomendação podem ajudar a aumentar o alcance de livros menos conhecidos e promover novos lançamentos, proporcionando maior diversidade de conteúdo e ampliando a visibilidade de obras que poderiam passar despercebidas. Essa inovação na experiência do usuário é um ganho tanto para os leitores quanto para as plataformas que utilizam o sistema, o que reforça sua importância na indústria editorial atual, tornando o projeto não apenas tecnicamente viável, mas academicamente rico e socialmente necessário. O alinhamento com os ODS reforça o compromisso com o impacto positivo na educação e na equidade de acesso à informação.

1.4. OBJETIVO GERAL E OBJETIVOS ESPECÍFICOS DA PESQUISA

Objetivo Geral:

- **Desenvolver um sistema de recomendação de livros** utilizando técnicas de aprendizado de máquina, com base na base de dados Book-Crossing, visando oferecer sugestões personalizadas que otimizem a experiência de leitura em ambientes digitais.

Objetivos Específicos

- **Explorar e compreender o dataset Book-Crossing:** realizar uma análise detalhada dos três conjuntos de dados disponibilizados (livros, usuários e avaliações), identificando sua estrutura, padrões e possíveis limitações.
- **Realizar limpeza e tratamento dos dados:** identificar e lidar com valores ausentes, inconsistências e possíveis ruídos nos dados para garantir a qualidade da modelagem;
- **Aplicar técnicas de aprendizado de máquina:** utilizar algoritmos como filtragem colaborativa, filtragem baseada em conteúdo e técnicas híbridas para construir modelos preditivos capazes de recomendar livros com base no perfil e nas preferências do usuário;
- **Avaliar o desempenho dos modelos:** empregar métricas para medir a qualidade das recomendações geradas;
- **Desenvolver e testar o sistema de recomendação:** implementar um protótipo funcional baseado nos dados do Book-Crossing Dataset, verificando sua eficácia na geração de recomendações personalizadas;
- **Aprimorar a personalização contínua:** incorporar funcionalidades que permitam aos usuários fornecer feedbacks sobre as recomendações, possibilitando adaptação e a evolução contínua das sugestões com base nas preferências individuais e nos comportamentos de leitura;
- **Desenvolver habilidades técnicas e analíticas:** aplicar os conhecimentos adquiridos durante o curso de Ciência de Dados, desenvolvendo habilidades práticas e técnicas em aprendizado de máquina, análise de dados e implementação de sistemas de recomendação, com ênfase em uma aplicação prática e realista no contexto editorial digital;

- **Promover o acesso facilitado à leitura e ao aprendizado contínuo (ODS 4 – Educação de Qualidade):** auxiliar os usuários na descoberta de livros adequados ao seu perfil e interesses, tornando-se uma ferramenta valiosa para incentivar a leitura e aprimorar o conhecimento, contribuindo para uma educação mais acessível e eficiente;
- **Promover o avanço tecnológico e a democratização do conhecimento (ODS 9 – Indústria, Inovação e Infraestrutura):** personalizar experiências e ampliar o acesso à informação representa um passo significativo para o desenvolvimento de soluções inovadoras no setor editorial e educacional;
- **Diminuir barreiras de acesso ao conhecimento (ODS 10 – Redução das Desigualdades)** tornando-o mais democrático e acessível a diferentes grupos sociais.

A extensão universitária, ao conectar a produção acadêmica com demandas sociais, torna este projeto um exemplo de como a ciência de dados pode ser aplicada para resolver problemas reais. Além de oferecer uma ferramenta tecnológica inovadora, o sistema de recomendação de livros pode estimular a leitura, aprimorar o aprendizado e reduzir desigualdades no acesso à informação.

Dessa forma, o projeto não apenas desenvolve uma solução computacional eficiente, mas também reforça seu compromisso com um futuro mais justo e sustentável, utilizando a tecnologia como meio de transformação social.

2. REFERENCIAL TEÓRICO

A ampla oferta de livros disponíveis em plataformas digitais e bibliotecas virtuais, embora represente um avanço no acesso à informação, tem tornado desafiadora a tarefa de identificar conteúdos relevantes que estejam alinhados aos interesses individuais dos leitores. Essa dificuldade está relacionada ao fenômeno da sobrecarga informacional, que compromete a experiência de leitura e reduz o engajamento com o conteúdo oferecido (Ricci; Rokach; Shapira, 2022). Diante desse cenário, os sistemas de recomendação (SRs) emergem como soluções essenciais para otimizar a jornada do usuário, promovendo a personalização das sugestões e facilitando a descoberta de novos títulos.

A hipótese central deste projeto fundamenta-se na premissa de que a utilização da técnica de filtragem colaborativa por fatoração matricial, em especial o Singular Value Decomposition (SVD), pode gerar recomendações úteis e personalizadas mesmo em bases

de dados esparsas, como o Book-Crossing Dataset. Esse tipo de abordagem se baseia na suposição de que usuários com comportamentos semelhantes no passado tendem a manter preferências semelhantes no futuro (Aggarwal, 2016). Tanto o algoritmo k-Nearest Neighbors (k-NN) quanto o SVD operam a partir da matriz de interações entre usuários e itens, permitindo identificar padrões de preferência latentes sem a necessidade de informações explícitas sobre os livros avaliados.

O SVD, especificamente, é amplamente reconhecido por sua eficiência em contextos nos quais há um grande número de usuários e itens, mas com baixo volume de interações por par, como é característico do Book-Crossing Dataset (Koren; Bell; Volinsky, 2009). A técnica realiza a decomposição da matriz usuário-item em fatores latentes, estimando avaliações ausentes com boa acurácia. Além disso, apresenta vantagens como baixo custo computacional, boa interpretabilidade e suporte robusto em bibliotecas amplamente utilizadas, como a Surprise, adotada neste projeto.

Apesar de suas vantagens, a filtragem colaborativa também apresenta limitações relevantes. A principal delas refere-se à esparsidade da matriz de avaliações, isto é, muitos usuários interagem com um número reduzido de livros, dificultando a identificação de padrões consistentes. Outra limitação importante é o problema do início frio (cold start), que ocorre quando o sistema precisa gerar recomendações para novos usuários ou livros que ainda não possuem histórico suficiente (KARIMI et al., 2022). Essas questões afetam diretamente a cobertura e a diversidade das recomendações geradas.

É precisamente nesse ponto que este projeto busca atuar: explorar a eficácia do SVD mesmo diante de um conjunto de dados esparsos, por meio de um pipeline estruturado que contempla etapas de pré-processamento, treinamento, avaliação e reavaliação do modelo. Estudos como o de Koren, Bell e Volinsky (2009) demonstram que o uso de fatoração matricial, como o SVD, revolucionou os sistemas de recomendação ao oferecer resultados precisos em ambientes reais, como no Netflix Prize.

Embora o SVD tenha sido a técnica escolhida neste projeto, outras abordagens também são amplamente utilizadas em sistemas de recomendação, sendo importante compreendê-las e contrastá-las:

- Filtragem baseada em conteúdo: realiza recomendações com base em atributos dos livros (ex.: autor, gênero, descrição). Apresenta bons resultados em contextos com metadados ricos, porém tende a gerar sugestões pouco diversas e repetir padrões conhecidos (AGGARWAL, 2022).

- Modelos híbridos: combinam múltiplas abordagens, como a filtragem colaborativa e a baseada em conteúdo, buscando mitigar as limitações de cada técnica isoladamente. São considerados o estado da arte em plataformas como Amazon, Netflix e Goodreads, embora exijam maior complexidade computacional e dados integrados (DELDJOO et al., 2022).
- Modelos baseados em redes neurais e aprendizado profundo: incluem arquiteturas como autoencoders, embeddings e transformers, capazes de capturar relações não lineares complexas. Apresentam alto desempenho em grandes bases, mas requerem alto poder computacional e são menos interpretáveis (MUSTO et al., 2021).
- Aprendizado por reforço: adapta-se às ações do usuário ao longo do tempo, ajustando as recomendações com base em feedback contínuo. É útil para plataformas dinâmicas e interativas, mas ainda enfrenta desafios de aplicação em sistemas com baixa frequência de interação (CHEN et al., 2023).

Diante desse panorama, a escolha do SVD neste projeto se justifica por três fatores principais: **(i)** alinhamento com o problema enfrentado — recomendação em bases esparsas; **(ii)** viabilidade técnica, considerando os dados disponíveis e os recursos computacionais; e **(iii)** comprovação de sua eficácia em diversos estudos acadêmicos e competições práticas.

Adicionalmente, o uso de SRs em contextos educacionais tem se mostrado promissor para apoiar o aprendizado personalizado, promover o engajamento e facilitar o acesso à informação (RAZA et al., 2022). Isso reforça o potencial social e pedagógico do sistema proposto, alinhando-o aos Objetivos de Desenvolvimento Sustentável (ODS), especialmente no que diz respeito à educação de qualidade, à redução de desigualdades e à inovação digital.

3. METODOLOGIA

A metodologia adotada neste projeto foi estruturada em etapas que permitiram a coleta, preparação, modelagem e avaliação de um sistema de recomendação de livros. A proposta parte do uso de uma base de dados real, associada a técnicas de aprendizado de máquina aplicadas no contexto da filtragem colaborativa. As etapas foram organizadas de modo a garantir reprodutibilidade e compatibilidade com os objetivos do projeto, alinhando-se às práticas da Ciência de Dados.

3.1. Coleta e Preparação dos Dados

Foi utilizada a base de dados Book-Crossing, composta por três arquivos contendo informações de livros, usuários e avaliações. Os dados foram obtidos pela plataforma Kaggle, originalmente organizados por Cai-Nicolas Ziegler (2004). Após a coleta, realizou-se o processo de limpeza e tratamento, que incluiu:

- Remoção de registros duplicados ou inválidos;
- Conversão dos identificadores (usuário e livro) para o formato adequado ao framework Surprise;
- Padronização da escala de avaliação para o intervalo de 1 a 10, por meio da classe Reader da biblioteca Surprise.

Esses procedimentos garantiram a integridade dos dados utilizados no treinamento e validação dos modelos, possibilitando uma análise estruturada e eficaz.

3.2. Escolha da Técnica de Modelagem

Foi adotada a técnica de filtragem colaborativa baseada em fatoração matricial, utilizando o algoritmo Singular Value Decomposition (SVD). Essa técnica é amplamente reconhecida por sua capacidade de lidar com dados esparsos e por apresentar bom desempenho em sistemas de recomendação baseados em interações.

A implementação foi realizada utilizando a biblioteca Surprise, no ambiente Google Colab, o que facilitou a experimentação e a replicação dos testes. A filtragem colaborativa com SVD permite a identificação de fatores latentes na matriz usuário-item, estimando avaliações não observadas com base nos padrões de comportamento dos usuários.

3.3. Estratégia de Treinamento e Avaliação

Para treinar e validar os modelos, foi empregada a técnica de validação cruzada com três partições (3-fold cross-validation), por meio da função `cross_validate()` da biblioteca Surprise. As métricas utilizadas para avaliação foram:

- RMSE (Root Mean Squared Error);
- MAE (Mean Absolute Error).

Essas métricas permitem quantificar a diferença entre as notas previstas e as notas reais fornecidas pelos usuários, oferecendo uma medida clara da performance preditiva dos algoritmos.

3.4. Ajustes e Modularização do Pipeline

Com base nos primeiros resultados, o pipeline de modelagem foi aprimorado. As principais modificações realizadas foram:

- Substituição de validação manual por uso da função `cross_validate()`;
- Criação da função `avaliar_modelo(algo, data, cv=3)` para padronizar e encapsular o processo de avaliação;
- Criação de um dicionário de algoritmos para facilitar a comparação entre modelos (ex.: SVD, BaselineOnly);
- Padronização da saída dos resultados com o uso de f-strings, promovendo maior legibilidade e organização do código;
- Remoção de blocos redundantes, tornando o pipeline mais limpo, reutilizável e escalável.

3.5. Comparação entre Modelos

Com o pipeline estruturado, foram avaliados dois algoritmos: o modelo de referência BaselineOnly (baseado em médias globais e desvios) e o modelo principal SVD. Essa comparação foi importante para verificar se o uso da fatoração matricial realmente proporcionaria um ganho em relação a abordagens mais simples.

Todos os experimentos foram realizados em ambiente Python, no Google Colab, utilizando as bibliotecas Surprise, Pandas, NumPy e Matplotlib, garantindo compatibilidade com ferramentas amplamente utilizadas na área de Ciência de Dados. A próxima seção apresenta os resultados obtidos com as avaliações dos modelos, bem como sua interpretação e implicações para o desempenho do sistema de recomendação proposto.

4. RESULTADOS

4.1. RESULTADOS PRELIMINARES

Para avaliar o desempenho do modelo de recomendação, foi utilizada a técnica de validação cruzada com três partições (3-fold cross-validation), aplicada tanto ao algoritmo SVD quanto ao modelo de referência BaselineOnly. O desenvolvimento do sistema de recomendação utilizou o Book-Crossing Dataset, que contém 278.858

registros de avaliações de livros feitas por 105.283 usuários únicos, além de informações detalhadas sobre 271.379 livros. Após o pré-processamento, que incluiu a remoção de inconsistências e valores ausentes, chegou-se a um conjunto de dados consolidado e adequado para análise.

Durante a fase experimental, foi utilizado o algoritmo de Filtragem Colaborativa baseada em SVD (Singular Value Decomposition), implementado com a biblioteca Surprise. O modelo foi avaliado por meio da função `cross_validate` com 3 folds, utilizando as métricas RMSE (Root Mean Squared Error) e MAE (Mean Absolute Error). Os resultados obtidos foram os seguintes:

Métrica	Fold 1	Fold 2	Fold 3	Média	Desvio Padrão
RMSE	3.5547	3.6723	3.8005	3.6758	0.1004
MAE	3.3414	3.4324	3.6311	3.4683	0.1210

O RMSE médio de 3.6758 indica um erro quadrático razoavelmente alto, o que sugere que o modelo ainda pode ser aprimorado, especialmente considerando a distribuição esparsa do conjunto de dados do Book-Crossing. O MAE médio de 3.4683 reforça que as previsões do modelo tendem a se desviar em média mais de 3 pontos da nota real (em uma escala de 1 a 10). O desvio padrão baixo em ambas as métricas (0.10 para RMSE e 0.12 para MAE) indica uma performance consistente entre os folds, o que é positivo em termos de estabilidade do modelo.

Portanto, apesar de os resultados não atingirem níveis ideais de precisão, são compatíveis com os desafios característicos de bases de dados esparsas e não balanceadas como o Book-Crossing. Esses dados contêm muitos usuários com poucas interações e uma grande variedade de livros, o que impacta diretamente a performance de modelos baseados em interação.

4.2. AJUSTES E MELHORIAS DO PIPELINE

Diante de limitações observadas, como redundância de código e dificuldade de interpretação dos resultados, foi realizada a reestruturação do pipeline. A nova versão tornou o código mais modular, reutilizável e eficiente, facilitando a comparação entre algoritmos e a reprodutibilidade dos resultados. Segue os ajustes técnicos realizados:

- **Substituição da Validação Manual por *cross_validate*:** a validação cruzada, antes executada com o controle manual de *KFold*, passou a utilizar a função *cross_validate*, da biblioteca Surprise, que permite calcular automaticamente métricas como **RMSE** e **MAE**. Isso simplificou o código e reduziu erros operacionais.
- **Criação da Função *avaliar_modelo()*:** para padronizar e encapsular o processo de avaliação, foi criada a função *avaliar_modelo(algo, data, cv=3)*, que executa a validação cruzada, calcula a média das métricas e formata os resultados. Esse encapsulamento permite reaproveitamento fácil do código para diferentes algoritmos.
- **Comparação entre Modelos:** um dicionário de modelos foi criado para testar e comparar o desempenho de diferentes algoritmos (como SVD e BaselineOnly) de maneira estruturada. Isso viabiliza a avaliação de múltiplas alternativas com clareza e padronização dos resultados.
- **Padronização das Saídas:** as saídas agora são exibidas com formatação uniforme, utilizando `print(f'{nome}: RMSE={{rmse:.4f}}, MAE={{mae:.4f}}')`, o que facilita a interpretação e comparação entre algoritmos.
- **Remoção de Redundância e Otimização da Manutenção:** blocos antigos de avaliação manual foram eliminados, tornando o código mais enxuto, organizado e preparado para futuras extensões, como tuning de hiperparâmetros e integração com conteúdo textual.

4.3. REAVALIAÇÃO DO DESEMPENHO DO MODELO

Com a reestruturação do pipeline e a criação da função *avaliar_modelo()*, os modelos passaram a ser avaliados de forma mais sistemática. A seguir, apresenta-se a média dos resultados obtidos após os ajustes:

Algoritmo	RMSE	MAE
BaselineOnly	3.6958	3.4820
SVD	3.6319	3.3808

Os resultados indicam que o modelo SVD apresenta desempenho superior ao modelo BaselineOnly, com menor erro nas predições tanto para RMSE quanto para MAE, mesmo

em um cenário com alta esparsidade de dados. Esses valores confirmam a consistência do modelo, embora indiquem uma margem de erro ainda elevada. Isso é compatível com as características do dataset Book-Crossing, que apresenta alta esparsidade e um número expressivo de usuários com poucas avaliações. Conforme discutido por Ricci et al. (2022), essa é uma limitação típica de sistemas baseados unicamente em filtragem colaborativa.

Com base nos dados obtidos, podemos constatar que o novo pipeline oferece uma base sólida para futuras melhorias, como: inclusão de modelos híbridos que combinem conteúdo textual dos livros com dados colaborativos; utilização de redes neurais para recomendações sequenciais ou baseadas em embeddings; exploração de métricas complementares como cobertura, novidade e diversidade, conforme sugerido por Zhang et al. (2019).

REFERÊNCIAS

- AGGARWAL, Charu C. *Recommender Systems: The Textbook*. Springer, 2016. Disponível em: <https://link.springer.com/book/10.1007/978-3-319-29659-3>. Acesso em: 1 mar. 2025.
- AGGARWAL, Charu C. *Recommender Systems: The Textbook*. 2. ed. Springer, 2022. Disponível em: <https://link.springer.com/book/10.1007/978-3-030-85447-8>. Acesso em: 30 mar. 2025.
- BASILICO, Justin; RICCI, Francesco. *Adaptive Recommender Systems: An Experimental Evaluation*. In: Proceedings of the 5th ACM Conference on Electronic Commerce, 2004, p. 239-246.
- BASILICO, J.; RICCI, F. *Adaptive Recommender Systems: An Experimental Evaluation*. ACM Transactions on Information Systems, 2020. Disponível em: <https://dl.acm.org/doi/10.1145/1122445.1122450>. Acesso em: 20 mar. 2025.
- BURKE, Robin. Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction*, v. 12, n. 4, p. 331–370, 2002. Disponível em: <https://link.springer.com/article/10.1023/A%3A1021240730564>. Acesso em: 12 maio 2025.
- CHEN, L.; ZHOU, T.; LI, Y. *Reinforcement Learning for Recommendation: Fundamentals, Applications and Future Directions*. ACM Computing Surveys, 2023. Disponível em: <https://dl.acm.org/doi/10.1145/3577192>. Acesso em: 30 mar. 2025.
- DELDJOO, Y.; TAFRESHI, S.; CANTADOR, I. *Hybrid Recommender Systems: A Systematic Review of the Literature and Future Research Directions*. *Information Fusion*, 81, 2022. Disponível em: <https://doi.org/10.1016/j.inffus.2022.01.002>. Acesso em: 30 mar. 2025.
- JANACH, D.; ADOMAVICIUS, G. *Recommender Systems: Challenges and Research Opportunities*. Computer Science Review, 2010. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S1574013710000147>. Acesso em: 1 mar. 2025.
- JANNACH, D.; ADOMAVICIUS, G. *Recommender Systems: Challenges and Research Opportunities*. Computer Science Review, 2021. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1574013721000175>. Acesso em: 20 mar. 2025.
- KARIMI, M.; JANNACH, D.; BALTRUNAS, L. *User-centric Evaluation of Recommender Systems: Foundations and Recent Trends*. *User Modeling and User-Adapted Interaction*, 2022. Disponível em: <https://doi.org/10.1007/s11257-022-09310-z>. Acesso em: 20 mar. 2025.
- KOREN, Yehuda; BELL, Robert; VOLINSKY, Chris. Matrix Factorization Techniques for Recommender Systems. *Computer*, v. 42, n. 8, p. 30–37, 2009. Disponível em: <https://dl.acm.org/doi/10.1109/MC.2009.263>. Acesso em: 12 maio 2025.
- MUSTO, C.; BORRELLI, N.; LOPS, P. *Deep Learning for Recommender Systems: A Review of Recent Advances*. *ACM Transactions on Intelligent Systems and Technology*, 2021. Disponível em: <https://doi.org/10.1145/3447548>. Acesso em: 30 mar. 2025.
- RESNICK, Paul; VARIAN, Hal R. Recommender Systems. *Communications of the ACM*, v. 40, n. 3, p. 56–58, 1997. Disponível em: <https://dl.acm.org/doi/10.1145/245108.245121>. Acesso em: 12 maio 2025.
- RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha. *Recommender Systems Handbook*. 3. ed. Springer, 2022. Disponível em: <https://link.springer.com/book/10.1007/978-1-0716-2197-4>. Acesso em: 12 maio 2025.

RUCHI, B. Conjunto de dados de cruzamento de livros. 2022. Disponível em: <https://www.kaggle.com/datasets/ruchi798/bookcrossing-dataset> . Acesso em: 1 mar. 2025.

SAID, A.; BELL, R.; WANG, X. *Recommender Systems in Education: Current Practices and Open Challenges*. *IEEE Transactions on Learning Technologies*, 2023. Disponível em: <https://ieeexplore.ieee.org/document/9979422> . Acesso em: 20 mar. 2025.

SCHAFER, J. Ben; KONSTAN, Joseph A.; RIEDL, *Recommender Systems: Challenges and Opportunities*. *Computer Science Review*, 2007. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S1574013707000096> . Acesso em: 1 mar. 2025.

SCHAFER, J. Ben; KONSTAN, Joseph A.; RIEDL, John. *E-commerce recommendation applications*. *Data Mining and Knowledge Discovery*, v. 5, p. 115-153, 2001.

SCHAFER, J. B.; KONSTAN, J. A.; RIEDL, J. *E-commerce recommendation applications*. *Data Mining and Knowledge Discovery*, 2021. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0167923621000859> . Acesso em: 20 mar. 2025.

ZIEGLER, Cai-Nicolas. *Book-Crossing Dataset*. Book-Crossing, 2004. Disponível em: <http://www.informatik.uni-freiburg.de/~cziegler/BX/> . Acesso em: 2 mar. 2025.

SciELO Brasil. Os Sistemas de Recomendação, Arquitetura da Informação e a Encontrabilidade da Informação. *Texto para Discussão*, 2016. Disponível em: <https://www.scielo.br/j/tinf/a/YsgLRc86K3WZfcbXPQHq7Vg/> Acesso em: 19 mar. 2025.

SciELO Brasil. Os sistemas de recomendação na web como determinantes prescritivos na tomada de decisão. *Revista JISTM*, 2012. Disponível em: <https://www.scielo.br/j/jistm/a/YQ58MyYNLHxgPqVvwpMQ8Bf/> . Acesso em: 19 mar. 2025.

Revista Iberoamericana de Tecnologia em Educação. A Aplicação de Sistemas de Recomendação no Contexto Educacional: uma Revisão Sistemática da Literatura. *ResearchGate*, 2022. Disponível em: https://www.researchgate.net/publication/361677333_A_Aplicacao_de_Sistemas_de_Recomendacao_no_Contexto_Educacional_uma_Revisao_Sistematica_da_Literatura/fulltext/638f81fde42faa7e759da385/A-Aplicacao-de-Sistemas-de-Recomendacao-no-Contexto-Educacional-uma-Revisao-Sistematica-da-Literatura.pdf . Acesso em: 19 mar. 2025.

Link GitHub: https://github.com/BrendaLOSCabral/Projeto_4-_Periodo.git

Link do Código:

https://colab.research.google.com/drive/1bW82v7CzrJzmZ7eBdQW2pC_V7lme_sik?usp=sharing